Лабораторная работа 6. Использование нейросетей для временных рядов

1. Цели

Получить базовые представления о работе и возможностях нейросетей. Построить нейросеть для решения задачи прогнозирования временных рядов с помощью готовых библиотек языка Python.

2. Задачи

1. Подключить библиотеку TensorFlow
2. Построить нейросеть модель для решения задачи регрессии с использованием рекуррентных слоев

3. Теоретические сведения

Методические указания для решения поставленного задания

3.1. Введение в нейронные сети

Нейронные сети – метод машинного обучения, часто используемый на практике. Нейронная сеть строится из простых вычислительных элементов – искусственных нейронов. Искусственные нейроны – попытка воссоздания работы нейрона головного мозга в упрощенном виде.

Нейронные сети способны решать большое количество задач, но лучше их применять для решения эвристических задач. В данной работе нейросеть будет предсказывать стоимость акций на основе анализа временных рядов

Основное отличие нейронных сетей от других методов машинного обучения заключается в выборе признаков среди набора данных. В методах машинного обучения выбором занимается человек, нейросети же определяют важные признаки во время своего обучения. Из-за данной особенности возрастают требования к мощности устройства, на котором происходит обучение сети.

Наиболее простой тип нейронной сети – сеть прямого распространения. Более подходящая для решения поставленной задачи архитектура – рекуррентная. Рекуррентная архитектура подразумевает циклы внутри сети, и подходит для задач прогнозирования последовательностей и работы с текстом.

3.2. Нейронные сети в Python

Для работы с нейронными сетями в данном курсе рекомендуется использовать библиотеку `TensorFlow` и её программный интерфейс `Keras.` Для установки библиотеки:

1. Откройте `Anaconda`
2. В меню слева выберете вкладку `Environments`
3. В списке установленных библиотек смените значение поля `Installed` на `Not installed`
4. В поле `Search Packages` впишите `tensorflow`
5. Среди найденных библиотек отметьте `tensorflow`
6. Нажмите на появившуюся снизу кнопку `Apply`

Пример построения и обучения нейросети с рекуррентной архитектурой будет приведен ниже, демонстрация будет проводится на участке отведенной бирже Euronext в наборе данных Stock Exchange Data (рус. Данные фондовых бирж)

3.2.1. Подготовка данных

Подключение библиотек – `matplotlib` для графиков, `numpy` для работы с тензорами

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import tensorflow as tf
```

Загрузка данных

```
PATH = "dataset/indexData.csv"
dataset = pd.read_csv(PATH)
```

Извлечение параметра цены из набора данных в переменную `price` хранящую одномерный тензор размерности `(5507,)`. Где `5507` – количество записей с ценой на момент закрытия биржи в определенную дату

```
EXCHANGE = "N100"
dataset = dataset[dataset["Index"] == EXCHANGE]
dataset = dataset.fillna(method='ffill')

price = np.array(pd.to_numeric(dataset["Close"]))
```

Для построения нейронной сети будет использоваться рекуррентная архитектура, а именно слои LSTM (рус. Долгая краткосрочная память). Слои LSTM принимают на вход трехмерные тензоры, где:

1. Первое число – общее количество записей
2. Второе число – количество записей, предшествующих записи с ценой
3. Третье число – количество записей с ценой

Ниже приведен код для создания трехмерного тензора `train_input` на основе одномерного тензора `price`. Количество записей, предшествующих записи с ценой, т. е. второе число трехмерного тензора – `20`

```
TIME_STEPS = 20

train_input = np.array([])
train_output = np.array([])

for index in range(TIME_STEPS, price.size):
    train_input = np.append(
        train_input,
        np.array(price[index - TIME_STEPS: index]),
    )
    train_output = np.append(
        train_output,
        np.array(price[index]),
    )

train_input = train_input.reshape(int(train_input.size / TIME_STEPS), TIME_STEPS, 1)
train_output = train_output.reshape(train_output.size, 1)
```

После чего получился тензор `train_input` размерности `(5487, 20, 1)`. Количество записей уменьшилось с `5507` до `5487` потому, что `20` записей в начале набора не могут иметь `20` предшествующих записей. Второе число зависит от переменной `TIME_STEPS` и выбирается по усмотрению. Третье число `1`, потому что у нас один входной признак – цена на момент закрытия.

Вместе с тензором `train_input` для содержащем входные признаки – последовательность цен за 20 дней, был создан тензор `train_output` для хранения выходных признаков – цену на 21 день. Размерность `train_output` – `(5487, 1)`, где первое число количество записей, а второе количество предсказаний.

Таким образом сеть будет предсказывать значение цены опираясь на значения предыдущих 20 значений.

3.2.2. Проектирование архитектуры нейросети

Создаётся переменная model для хранения нейросети, после чего в неё добавляются три слоя

1. Слой LSTM – 256 нейронов, размерность входных данных (20, 1), функция активации `relu` (рус. Выпрямленный линейный блок), возвращает всю последовательность поданных данных
2. Слой LSTM – 64 нейрона, размерность входных данных настраивается автоматически, функция активации `relu`, возвращает только результат
3. Слой Dense (рус. Полносвязный слой) – 1 нейрон

Данная архитектура не является эталонной для данной задачи, но показывает хорошие результаты. Попробуйте изменить количество слоёв LSTM и количество нейронов на этих слоях, также попробуйте другие функции активации

```
model = tf.keras.models.Sequential()

model.add(
    tf.keras.layers.LSTM(
        256,
        input_shape =
        (
            train_input.shape[1],
            train_input.shape[2]
        ),
        activation="relu",
        return_sequences=True)
)

model.add(
    tf.keras.layers.LSTM(
        64,
        activation="relu",
        return_sequences=False
    )
)

model.add(
    tf.keras.layers.Dense(1)
)

model.compile(
    optimizer='Adam',
    loss='mse',
)

model.build(train_input.shape)
model.summary()
```

После добавления слоев, нейросеть подготавливается методами `compile` и `build`. Архитектуру сети можно узнать, вызвав метод `summary`

Используемые параметры обучения:

- Оптимизатор – `Adam` (рус. Адаптивная оценка моментов). Не эталонный – попробуйте другие
- Метрика ошибки – `mse` (рус. Среднеквадратическая ошибка)

3.2.3. Обучение нейросети

Нейросеть начинает обучаться при вызове метода `fit` в который передаются параметры

1. `train_input` – Входные признаки
2. `train output` – Выходные признаки

3. `validation split` – разделение выборки на обучающую и проверочную, выбрано использовать `0.2` выборки как проверочные
4. `epochs` – количество эпох для обучения сети
5. `verbose` – вывод данных об обучении на экран

Количество эпох не является эталонным, попробуйте разные значения. Также на вашем устройстве может не хватить оперативной памяти для обучения нейросети – для решения этой проблемы используется параметр `batch_size`, попробуйте разные значения, которые обычно принимаются степенью двойки.

```
history = model.fit(
    train_input,
    train_output,
    # batch_size=128,
    validation_split=0.2,
    epochs=20,
    verbose=True,
)
```

Далее, проверяем пригодность нейросети проверяя среднеквадратическую ошибку её предсказаний на тестовом наборе и вместе с тем сохраняя модель

```
error = int(
    model.evaluate(
        train_input,
        train_output
    )
)

model.save(f"model/{model.loss} {error}.h5")
```

Позже модель можно будет загрузить, передав её в переменную методом `load_model`

```
model = tf.keras.models.load_model("model/mse 258.h5")
```

Далее строим график для проверки работы нейросети

```
plt.plot(train_output)
plt.plot(
    model.predict(
        train_input,
        verbose=False
    )
)
plt.show()
```

Ниже представлен график работы нейросети:

1. Зеленая линия – эталонные значения
2. Оранжевая линия – предсказания сети

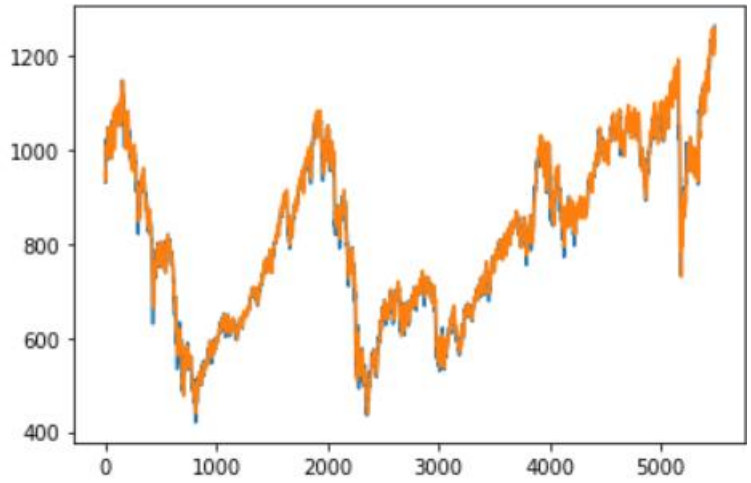

Среднеквадратическая ошибка сети – 258

3.2.4. Предсказание

Далее представлен код для предсказания значений цен на следующие 365 дней отсутствующих в наборе. Так как нейросеть обучалась на последовательностях из 20 значений, то и предсказания она делает, получая на вход только такие же последовательности, за создание таких последовательностей отвечает цикл в коде ниже

```
PREDICTIONS_NUMBER = 365

prediction_input = train_input.copy()
prediction_output = np.array([])

for _ in range(PREDICTIONS_NUMBER):
    prediction = model.predict(
        prediction_input[-1].reshape(1, TIME_STEPS, 1),
        verbose=False
    )
    prediction_output = np.append(
        prediction_output,
        prediction
    )

    new_time_series = prediction_input[-1][1:]
    new_time_series = np.append(new_time_series, [prediction])

    shape = prediction_input.shape

    prediction_input = np.append(
        prediction_input,
        [new_time_series]
    )

    prediction_input = prediction_input.reshape(
        int(prediction_input.shape[0] / shape[1]),
        shape[1],
        shape[2]
    )

prediction_output = prediction_output.reshape(
    PREDICTIONS_NUMBER,
    1
)

prediction_output
```

После выполнения кода на экран должны выводится предсказанные значения в текстовом виде.

Для вывода этих же данных используется следующий код

```
prediction_output = np.append(
    train_output,
    prediction_output
)

plt.plot(prediction_output)
plt.plot(train_output)
plt.show()
```

Полученный график:

- Оранжевая линия – имеющиеся данные
- Синяя линия – предсказанные значения

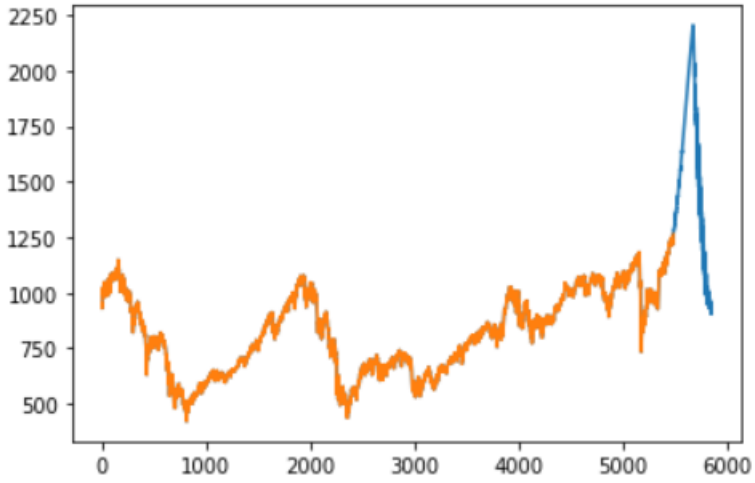

4. Задание

Выбрать с сайта `kaggle.com` набор данных в формате `.csv`, содержащий данные типа «дата-значение». Загрузить и подготовить его к дальнейшей обработке. Наборы данных не должны повторяться внутри группы. Задание индивидуальное. Требования:

1. Подготовить данные к обработке слоем LSTM
2. Построить нейросеть
3. Обучить нейросеть
4. Сравнить эталонные значения и предсказания на данных для обучения
5. Предсказать следующие 20 значений
6. Сохранить нейросеть
7. Сохранить `IPython Notebook`

4.1. Продвинутое задание

Улучшить архитектуру нейросети с помощью Keras Tuner